DBO na entrada com JEPA

Previsão no espaço do embedding

SoftSensor

16 de outubro de 2026

1 Objetivo

Estimar a DBO na entrada, `DBO-E`, a partir de 10 leituras de DQO (`DQO-E`) e de SST (`SS-E`). A fila é a mesma da rede recorrente: o dia estimado e as nove leituras anteriores disponíveis.

JEPA (*Joint-Embedding Predictive Architecture*) treina a previsão no espaço de um vetor, não no número da DBO. Um codificador transforma a fila em um vetor. Outro transforma a DBO em um vetor do mesmo tamanho. Um preditor tenta reproduzir o vetor da DBO a partir do vetor da fila. A perda é a distância entre esses dois vetores. Uma penalidade de variância empurra cada eixo do vetor para não encolher até zero. A DBO numérica sai depois, por uma regressão linear lida no vetor da fila. Na hora do teste o codificador da DBO não é usado: a planta só oferece DQO e SST.

2 Dados e protocolo

O corte temporal é o da RNN, para os dois resultados se referirem aos mesmos dias. São 498 dias completos na entrada. As 389 janelas mais antigas treinam. As 100 mais recentes, de 29 de maio a 29 de outubro de 1991, testam. A validação cruzada é temporal, com 5 partições, e escolhe a configuração pelo MAE dessa reta de leitura.

A grade cobre larguras ocultas de 16 e 32, embeddings de 8 e 16, e taxas 10^{-3} e 10^{-2}. O peso da penalidade de variância é 0,2. O ajuste final repete, em todas as janelas de treino, o número mediano de épocas da configuração vencedora. A reta de leitura é ajustada só no treino.

3 Resultados

A validação escolhe largura 32, embedding de 8 e taxa 10^{-2}. O MAE nas partições é 46,29, com desvio 6,05. A parada ocorre em 1 época. A rede tem 1816 parâmetros. As oito configurações ficam entre 46,29 e 50,60 de MAE, e todas param em no máximo 16 épocas. Alongar o treino do embedding piora a DBO na validação.

Tabela 1: Erro nos mesmos 100 dias finais usados na RNN.

Modelo	MAE	RMSE	R^2
Média do treino	40,88	48,15	−0,73
Linear da leitura atual	33,13	40,75	−0,24
Linear das 10 leituras	34,08	42,83	−0,37
RNN	32,00	40,68	−0,23
JEPA	32,78	41,39	−0,28

A linha da RNN é a do relatório anterior, neste mesmo corte. Ela não foi retreinada aqui.

No teste, a previsão do JEPA vai de 122,15 a 303,87, e a DBO observada vai de 84 a 277. O resíduo médio é −22,06. A mediana do erro absoluto é 27,42 e o percentil 90 é 70,11. Em 55 dos 100 dias o erro absoluto fica até 30; em 76 dias, até 50.

No treino, o desvio médio do embedding da fila é 0,528. O da DBO é 0,061 e o do vetor previsto é 0,119. A penalidade pedia desvio perto de 1. A correlação média, eixo a eixo, entre o vetor previsto e o vetor da DBO é −0,02. O erro quadrático entre eles é 0,022, pequeno porque os dois vetores estão encolhidos, não porque um acompanha o outro.

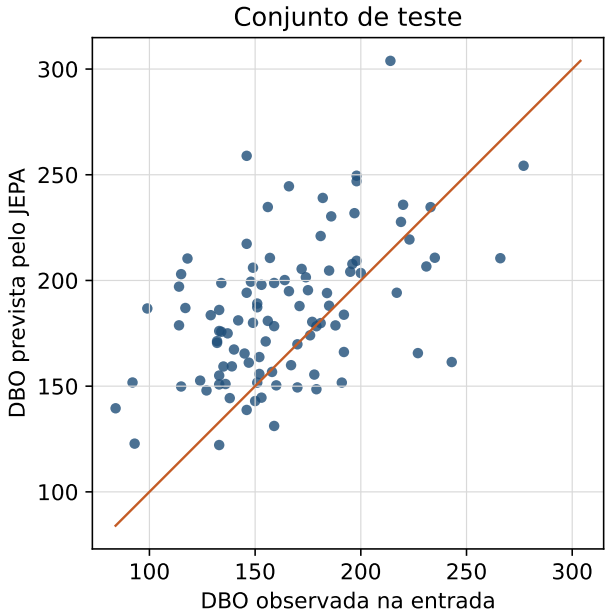


Figura 1: Teste do JEPA. A nuvem fica acima da reta de igualdade: a previsão segue o nível mais alto do treino.

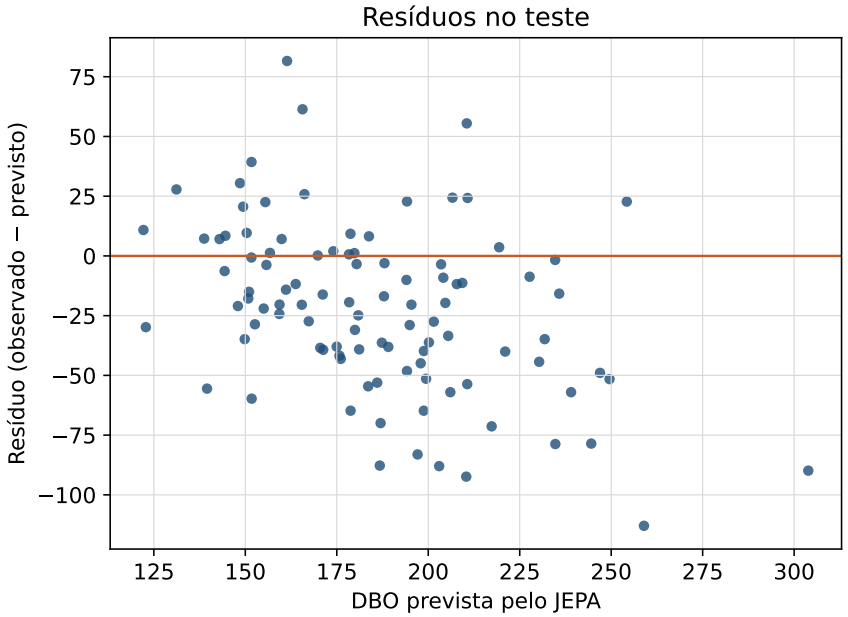


Figura 2: Resíduos no teste. O centro está abaixo de zero, e o erro cresce nas previsões mais altas.

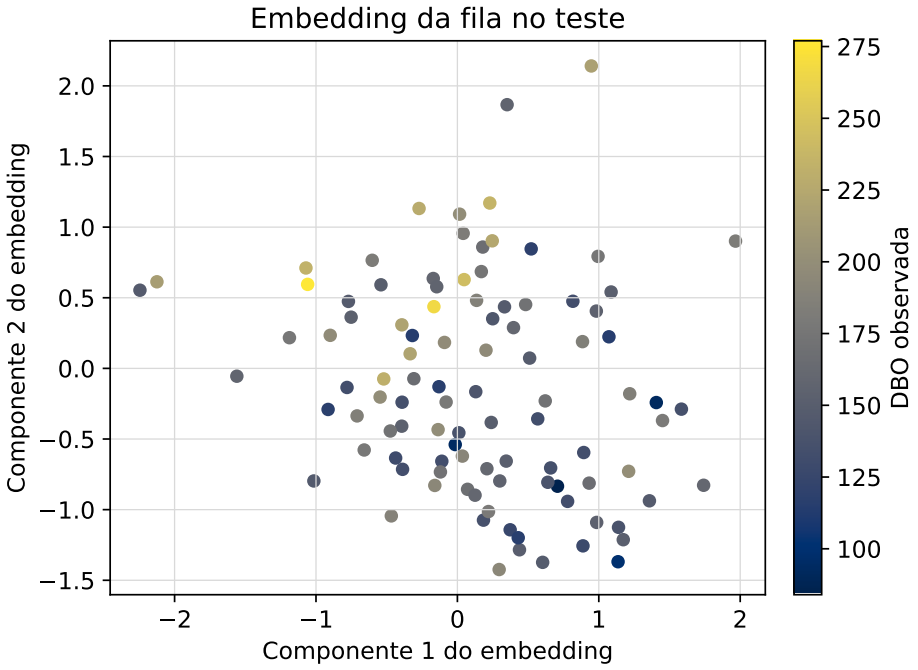


Figura 3: Embedding da fila no teste, em duas componentes. A cor é a DBO observada. Amarelo e azul dividem as mesmas regiões.

4 Leitura

O JEPA reduz o MAE de 40,88 para 32,78 em relação à média do treino. Fica 0,35 abaixo da reta da leitura atual e 0,78 acima da RNN. O RMSE, 41,39, fica acima dos dois. O R^2 de $-0{,}28$ repete o deslocamento já visto na RNN: o treino vive em torno de 195 e o teste em torno de 164, e a previsão permanece cerca de 22 unidades acima das observações finais.

O treino do embedding não organizou a DBO. A validação escolheu a primeira época porque as épocas seguintes aumentavam o MAE da leitura. O vetor da DBO ficou com desvio 0,061, longe do alvo 1 da penalidade, e a correlação com o vetor previsto é nula. A Figura 3 mostra o mesmo: a cor da DBO não desenha uma escala no plano. A reta de leitura, aplicada a um vetor quase cru, é quem produz o número. Com 1816 parâmetros, o JEPA não separa essa reta nem a RNN de 97 parâmetros.

A Figura 1 e a Figura 2 mostram o mesmo viés do período final. DQO e SST recentes ainda empurram a estimativa para o patamar antigo. Prever o vetor da DBO, em vez do número, não corrige essa mudança de nível.

5 Conclusão

Com a fila de 10 leituras, o JEPA chega a MAE 32,78, RMSE 41,39 e R^2 −0,28 nos 100 dias finais. A RNN, no mesmo corte, chega a MAE 32,00 e RMSE 40,68. A reta da leitura atual chega a MAE 33,13 e RMSE 40,75. O embedding previsto não acompanha o embedding da DBO, e a validação encerra o treino na primeira época. Nesta amostra, a arquitetura preditiva de embeddings não melhora a estimativa.

O notebook é `modelo/jepa_dbo_entrada.ipynb`. A RNN está em `docs/rnn_dbo_entrada.pdf`.