DBO na entrada a partir de DQO e SST

Rede neural e validação cruzada

SoftSensor

16 de outubro de 2026

1 Objetivo

Estimar a demanda bioquímica de oxigênio na entrada da estação, `DBO-E`, com duas medições do mesmo ponto: a demanda química de oxigênio, `DQO-E`, e os sólidos em suspensão, `SS-E`. No arquivo, `SS-E` é o SST. A data não entra no modelo. Cada dia é uma observação independente.

2 Dados

O conjunto é o Water Treatment Plant, de Manel Poch (UCI, 1993). São 527 dias. Ficam 498 dias em que `DBO-E`, `DQO-E` e `SS-E` existem ao mesmo tempo; 29 dias saem por valor ausente. Não há interpolação. As unidades não estão documentadas na UCI, e os erros abaixo usam a mesma escala do arquivo.

Tabela 1: Entrada da planta nos 498 dias completos.

Variável	Mínimo	Mediana	Média (desvio)	Máximo
DBO-E	31	182,5	188,72 (62,28)	438
DQO-E	81	397,5	405,36 (119,99)	941
SS-E	98	198	228,74 (139,12)	2008

A correlação da DBO com a DQO é 0,565. Com o SST é 0,137. DQO e SST correlacionam 0,284 entre si. O máximo de `SS-E`, 2008, fica muito acima da mediana 198.

3 Protocolo

A amostra foi embaralhada e partida em 80% de treino (398 dias) e 20% de teste (100 dias), com `random_state` 42. A DBO média é 188,14 no treino e 191,03 no teste.

A rede é um `MLPRegressor` com otimizador `lbfgs`, adequado a este tamanho de amostra. As entradas passam por um `StandardScaler` dentro de um `Pipeline`, ajustado só nas linhas de treino de cada partição. A validação cruzada tem 5 partições embaralhadas e escolhe a configuração de menor MAE. A grade cobre camadas (8), (16), (32), (16, 8) e (32, 16), ativações ReLU e tangente hiperbólica, e regularização L2 $\alpha \in \{10^{-4}, 10^{-3}, 10^{-2}, 10^{-1}\}$.

O teste é usado uma vez, depois da escolha. Duas referências, ajustadas no mesmo treino, situam o erro: a média da DBO de treino e uma regressão linear de `DQO-E` e `SS-E`.

4 Resultados

A validação cruzada escolhe uma camada de 8 neurônios, ReLU e $\alpha = 10^{-4}$. O MAE nessa validação é 39,19, com desvio de 2,78 entre as partições. O ajuste final converge em 42 iterações. As oito melhores configurações ficam entre 39,19 e 39,99 de MAE. Trocar o tamanho da rede, a ativação ou α mexe pouco no erro, e a rede menor permanece na frente.

Tabela 2: Erro no conjunto de teste (100 dias).

Modelo	MAE	RMSE	R^2
Média do treino	44,11	56,83	0,00
Regressão linear	32,96	44,76	0,38
MLP	33,51	44,91	0,37

Na validação cruzada do treino, a regressão linear tem MAE 38,36 ± 2,08, e o MLP tem 39,19 ± 2,78. A ordem se repete no teste. O teste ficou um pouco mais fácil do que as partições de validação, para os dois modelos.

A reta ajustada nas unidades originais é

$$\widehat{\mathrm{DBO}} = 74{,}04 + 0{,}2872\,\mathrm{DQO} - 0{,}0127\,\mathrm{SST}. \tag{1}$$

Num dia com DQO 400 e SST 200, a conta dá cerca de 186, perto da média da amostra. O coeficiente do SST é pequeno: cada unidade a mais de SST reduz a DBO prevista em 0,013.

Embaralhar a DQO no treino aumenta o MAE do MLP em 19,15 ± 1,39. Embaralhar o SST aumenta o MAE em 0,10 ± 0,08.

No teste, a previsão do MLP vai de 95,86 a 273,91. O resíduo médio (observado menos previsto) é 5,21. A mediana do erro absoluto é 22,07 e o percentil 90 é 79,31. Em 59 dos 100 dias o erro absoluto fica até 30; em 74 dias, até 50.

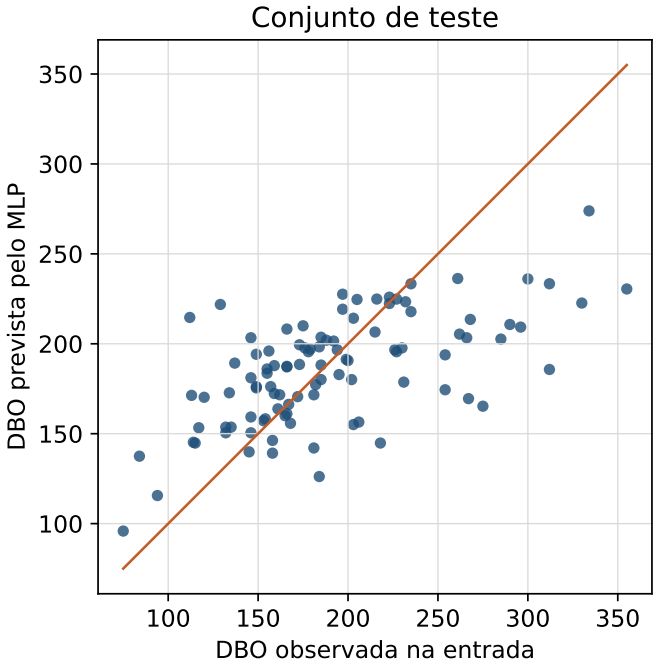


Figura 1: Teste do MLP. A reta marca a previsão igual à DBO observada. Abaixo dela, a rede fica aquém da observação.

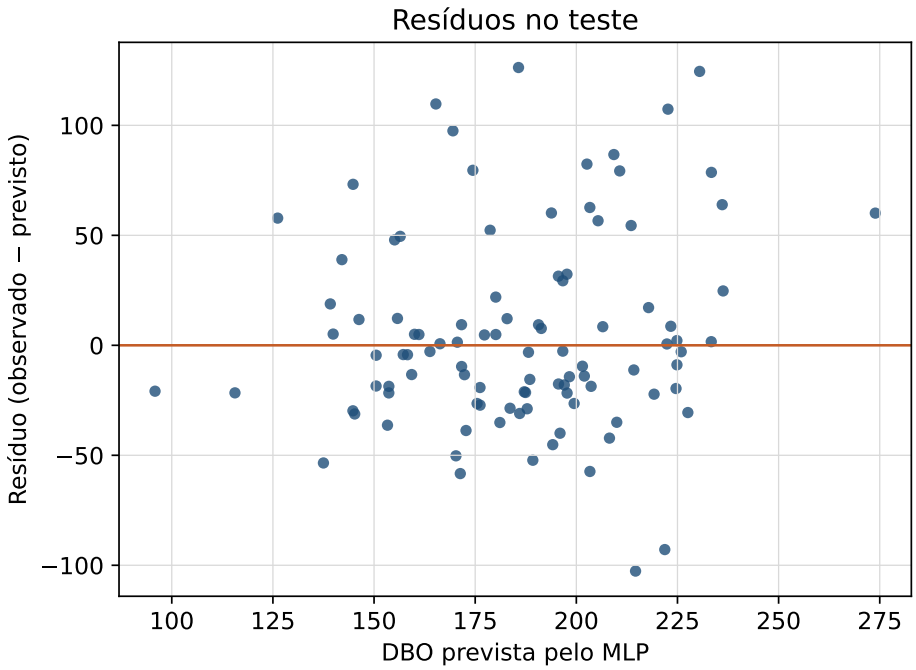


Figura 2: Resíduos no teste. A dispersão permanece larga em toda a faixa prevista.

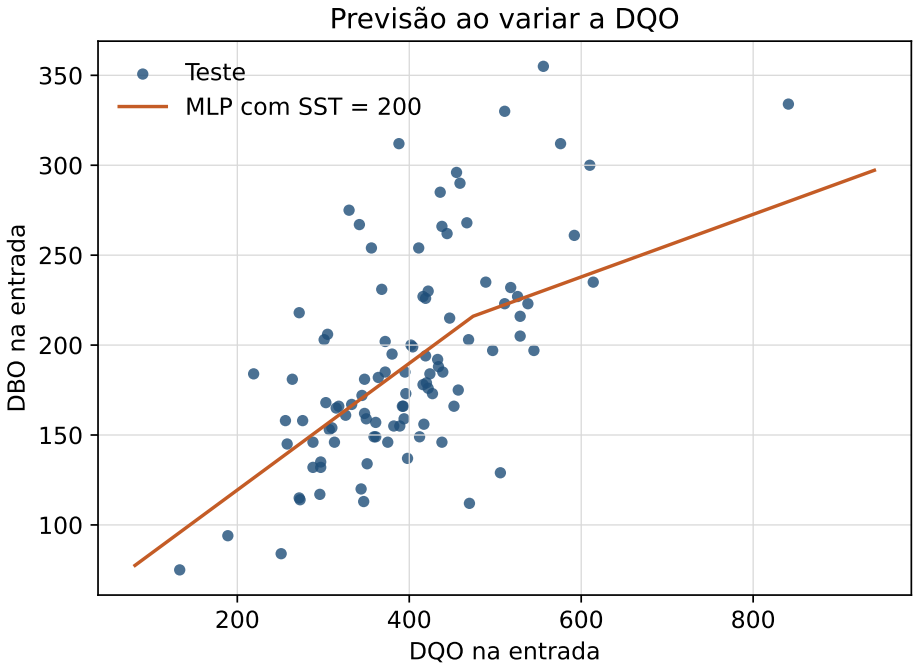


Figura 3: DBO e DQO no teste. A curva é o MLP com o SST fixo em 200, a mediana do treino.

5 Leitura

O MLP reduz o MAE de 44,11 para 33,51 em relação a prever sempre a média do treino, cerca de um quarto a menos. O R^2 de 0,37 deixa a maior parte da variação da DBO por explicar. O erro médio no teste equivale a cerca de 18% da DBO média desse conjunto (191).

A mediana do erro, 22, é bem menor que o MAE, 33,5. Poucos dias puxam a média: um em cada dez erra 79 ou mais. O RMSE de 44,91, acima do MAE, descreve essa cauda.

A nuvem da Figura 2 ocupa de cerca de -100 a $+130$ em qualquer região da previsão. Na Figura 1, DBO baixa fica acima da reta e DBO alta fica abaixo: a rede comprime os extremos. No teste a previsão vai até 274, enquanto várias observações passam disso e outras ficam abaixo de 100.

A curva da Figura 3, com SST fixo, é quase uma reta, com uma leve mudança de inclinação depois de DQO perto de 500, região com poucos dias. A regressão linear fica à frente do MLP por uma margem pequena, na validação cruzada e no teste. Com duas entradas e esta amostra, a rede de 8 neurônios reproduz uma relação praticamente linear. Redes maiores na grade ficam no mesmo patamar de erro.

O sinal útil está na DQO. O SST, mesmo com um valor extremo de 2008, deixa o MAE praticamente no mesmo lugar. Para este alvo e estas duas entradas, a descrição que cabe aos dados é a reta da equação anterior: a DBO prevista sobe cerca de 0,29 unidade por unidade de DQO.

A divisão trata os dias como independentes, que foi a regra desta análise. Dias vizinhos no calendário podem ter carga parecida; um teste cronológico, com o futuro separado do passado, pode dar erro maior do que o reportado aqui.

6 Conclusão

Com DQO e SST da entrada, o MLP chega a MAE 33,51, RMSE 44,91 e R^2 0,37 nos 100 dias de teste. A regressão linear chega a MAE 32,96, RMSE 44,76 e R^2 0,38, e também fica à frente na validação cruzada. A DQO carrega a estimativa. O SST fica sem efeito prático. O modelo acompanha o centro da DBO e se afasta nos dias extremos.

O notebook com o ajuste, a grade e os gráficos é `modelo/mlp_dbo_entrada.ipynb`.